



Faculdade de Informática e Administração Paulista

DATABASE APPLICATION AND DATA SCIENCE

ENTREGÁVEL DA DISCIPLINA

INTEGRANTES

RM (SOMENTE NÚMEROS)	NOME COMPLEMENTO (SEM ABREVIAR)
95657	Enzo Perazolo
94767	Giovanna Sousa
93443	Henry Kinoshita
94538	Luiz Felipe
93772	Matheus Felipe
92843	Victor Mendes

Sumário

DESCRIÇÃO DO PROJETO E REGRAS DE NEGÓCIOS.....	4
Projeto Lógico do Banco de Dados:	12
Projeto Relacional do Banco de Dados:	13

Descrição do Projeto e Regras de Negócios

Declaração de Visão e Escopo do Projeto

Descrição do problema a resolver:

A jornada do cliente (CX) é uma parte crucial do sucesso de qualquer negócio. No entanto, muitas empresas lutam para fornecer uma experiência personalizada e satisfatória para seus clientes. O problema é a falta de uma solução eficiente para fornecer recomendações personalizadas e prever as necessidades dos clientes com base em seu histórico de compras e interações anteriores com a marca.

Descrição dos objetivos da solução idealizada:

O objetivo desta solução é utilizar a tecnologia de Machine Learning para criar um sistema que possa aprender com as interações anteriores dos clientes e fornecer recomendações personalizadas cada vez mais precisas. A solução deve ser capaz de prever as necessidades dos clientes, fornecendo-lhes ofertas personalizadas e melhorando sua experiência de compra.

O sistema é composto por dois componentes principais: um modelo de recomendação e um modelo de previsão:

- O modelo de recomendação é treinado com dados históricos de interações do cliente com a marca, como compras anteriores, navegação em sites, pesquisas e outros dados relevantes. O modelo usa esses dados para gerar recomendações personalizadas para cada cliente, levando em consideração suas preferências, histórico de compras e outros fatores.
- O modelo de previsão utiliza técnicas de Machine Learning para prever as necessidades futuras dos clientes com base em seus dados históricos. Ele considera fatores como sazonalidade, tendências de mercado e mudanças nos comportamentos dos clientes. Com base nessas previsões, o modelo é capaz de fornecer recomendações mais precisas e relevantes para os clientes, aumentando a probabilidade de que eles realizem uma compra.

Além disso, a solução também inclui um sistema de feedback que permite aos clientes avaliar as recomendações recebidas. Esses feedbacks são usados para ajustar e melhorar continuamente o modelo de recomendação e o modelo de previsão.

Definição do público-alvo que comprará (cliente/pagante) e/ou usará a solução (consumidor):

O público-alvo desta solução são empresas que buscam melhorar a experiência de seus clientes. Os consumidores finais são os clientes das empresas que utilizarão a solução.

As necessidades e desejos do público-alvo em relação ao problema incluem

- Personalização: os clientes desejam uma experiência personalizada e única que atenda às suas necessidades e preferências individuais.
- Facilidade de uso: os clientes querem que a experiência de compra seja fácil e intuitiva, sem barreiras ou obstáculos desnecessários.
- Agilidade: os clientes esperam uma experiência rápida e ágil, sem atrasos ou tempos de espera prolongados.
- Confiança: os clientes desejam confiar na marca e em seus produtos, ter certeza de que estão fazendo uma compra com boa relação custo-benefício.
- Comunicação clara: os clientes querem que as informações fornecidas pela marca sejam claras, precisas e relevantes para suas necessidades.
- Relevância: os clientes esperam que as recomendações e sugestões fornecidas pela marca sejam relevantes e apropriadas para seus interesses e necessidades individuais.
- Personalização contínua: os clientes querem que a marca continue a aprender e ajustar as recomendações e sugestões ao longo do tempo, para que a experiência continue a ser personalizada e relevante.

Descrição das possíveis bibliotecas e frameworks Python que poderão ser utilizados:

- TensorFlow: é uma biblioteca de código aberto para aprendizado de máquina e inteligência artificial desenvolvida pela Google. É amplamente utilizada para criação de modelos de redes neurais profundas e pode ser utilizado para a criação de chatbots avançados.
- Keras: é uma biblioteca de alto nível para aprendizado de máquina e redes neurais escrita em Python, que roda em cima do TensorFlow. É uma das bibliotecas mais utilizadas para criação de modelos de redes neurais e possui uma sintaxe simples e intuitiva.
- Scikit-learn: é uma biblioteca de aprendizado de máquina em Python que oferece uma ampla variedade de algoritmos para tarefas de classificação, regressão, clusterização, entre outras. É uma das bibliotecas mais populares para análise de dados e criação de modelos de aprendizado de máquina.
- NLTK (Natural Language Toolkit): é uma biblioteca em Python para processamento de linguagem natural. Pode ser utilizado para lidar com tarefas como tokenização, lematização, análise de sentimentos, entre outras.
- Pandas: é uma biblioteca em Python para manipulação e análise de dados. É frequentemente utilizada para limpeza, transformação e análise de dados em projetos de aprendizado de máquina e inteligência artificial.

No projeto proposto, a IA (Inteligência Artificial) será utilizada para desenvolver um sistema de recomendação personalizada para os clientes, a fim de prever suas necessidades com base em seu histórico de compras e interações anteriores com a marca. Para isso, serão utilizados algoritmos de aprendizado de máquina e redes neurais, que serão treinados com os dados históricos dos clientes, a fim de prever suas necessidades e fornecer recomendações precisas e personalizadas.

O conceito de LOT (Language of Thought) também será utilizado na solução proposta. Isso porque, a partir das interações com os clientes, será possível aprender a linguagem específica utilizada pelos clientes e criar um modelo cognitivo da linguagem desses clientes. Com essa informação, a IA poderá ser treinada para compreender melhor as necessidades e desejos dos clientes e fornecer recomendações mais precisas e personalizadas.

Além disso, a utilização da linguagem natural na interação com os clientes também será fundamental para a solução proposta. Com o uso de bibliotecas como NLTK (Natural Language Toolkit) e TensorFlow, será possível treinar modelos de processamento de linguagem natural para compreender melhor as necessidades e desejos dos clientes e fornecer recomendações mais precisas e personalizadas.

Em resumo, a IA e o conceito de LOT serão utilizados de forma integrada na solução proposta, a fim de criar um sistema de recomendação personalizada e inteligente, capaz de compreender a linguagem dos clientes e prever suas necessidades com base em seu histórico de compras e interações anteriores com a marca.

Estudo de produtos semelhantes já existentes no mercado (que solucionam o mesmo problema, mesmo que de forma diferente, parcial ou totalmente):

Há muitas soluções de recomendação personalizadas no mercado, desde sistemas de recomendação de filmes até recomendações de produtos em lojas online. No entanto, a maioria dessas soluções não utiliza Machine Learning para melhorar a precisão das recomendações e não levam em conta o histórico completo de interações com a marca. A solução proposta irá superar essas limitações.

- Amazon Personalize: a Amazon oferece um serviço de personalização de recomendação que permite que as empresas personalizem suas recomendações de produtos com base no histórico de compras e no comportamento do usuário.
- Salesforce Einstein: o Salesforce Einstein é uma plataforma de inteligência artificial que ajuda as empresas a oferecer recomendações personalizadas para seus clientes.
- Adobe Target: a Adobe Target é uma plataforma de personalização que usa dados do cliente e inteligência artificial para fornecer recomendações personalizadas.
- Google Analytics 360: o Google Analytics 360 é uma plataforma de análise de dados que ajuda as empresas a entender o comportamento do cliente e fornecer recomendações personalizadas.
- Dynamic Yield: a Dynamic Yield é uma plataforma de personalização omnichannel que usa aprendizado de máquina para fornecer recomendações personalizadas e experiências personalizadas para os clientes.

Para se destacar em relação aos produtos concorrentes, a solução proposta pode explorar as seguintes oportunidades de diferenciação:

- Integração com outras ferramentas de CX: a solução pode se integrar com outras ferramentas de CX (Customer Experience), como plataformas de e-commerce e ferramentas de análise de dados, para fornecer uma experiência de compra mais integrada e completa.
- Foco em segmentos específicos de mercado: a solução pode se concentrar em atender a segmentos específicos de mercado, como nichos de mercado ou setores da indústria, com recursos personalizados e adaptados às suas necessidades.
- Monitoramento contínuo do feedback do cliente: a solução pode incorporar recursos de monitoramento e análise contínua do feedback do cliente para garantir que as recomendações e sugestões permaneçam relevantes e atualizadas ao longo do tempo.

Avaliação do potencial de mercado (fatia de mercado a conquistar):

O mercado para soluções de recomendação personalizadas está em crescimento, com muitas empresas buscando maneiras de melhorar a experiência do cliente. A solução proposta tem potencial para conquistar uma fatia significativa do mercado, uma vez que será capaz de fornecer recomendações cada vez mais precisas e personalizadas, melhorando a satisfação do cliente e aumentando a fidelidade do cliente para com a marca.

- Aumento da demanda por experiências de compra personalizadas: os consumidores estão cada vez mais em busca de experiências de compra personalizadas, o que cria uma oportunidade para soluções que utilizam

aprendizado de máquina e análise de dados para fornecer recomendações e sugestões personalizadas.

- Crescimento do mercado de CX: o mercado de CX está em constante crescimento e deve continuar crescendo nos próximos anos, criando uma oportunidade para soluções que oferecem uma experiência de compra mais personalizada e integrada.
- Ampliação da adoção de tecnologias de IA: a adoção de tecnologias de inteligência artificial, como aprendizado de máquina, está em constante crescimento, o que cria uma oportunidade para soluções que utilizam essas tecnologias para fornecer uma experiência de compra mais personalizada e adaptada às necessidades do cliente.
- Diferenciação em relação aos concorrentes: oferecer recursos e funcionalidades exclusivas e diferentes dos concorrentes pode ajudar a solução proposta a se destacar no mercado e conquistar uma fatia maior de clientes em busca de uma experiência de compra personalizada.
- Expansão para novos mercados: a solução proposta pode ser expandida para novos mercados e setores da indústria, adaptando-se às necessidades e demandas específicas de cada segmento e aumentando seu potencial de crescimento no mercado.

A solução proposta cria valor para o público-alvo de diversas formas:

- Melhora a experiência do cliente: Ao fornecer recomendações mais precisas e personalizadas, a solução melhora a experiência do cliente, aumentando a satisfação e a fidelidade à marca.
- Economiza tempo: Ao antecipar as necessidades do cliente, a solução economiza tempo do cliente ao tornar mais rápida e fácil a busca por produtos que atendam suas necessidades.
- Aumenta a relevância: Ao fornecer recomendações personalizadas, a solução aumenta a relevância das ofertas, aumentando a probabilidade de o cliente comprar e, conseqüentemente, aumentando as vendas da marca.
- Melhora a eficiência: Ao utilizar técnicas de inteligência artificial, a solução pode processar grandes quantidades de dados de forma eficiente e automatizada, permitindo que a marca ofereça recomendações personalizadas para um grande número de clientes simultaneamente.
- Estimula a compra recorrente: A solução pode ser utilizada para incentivar a compra recorrente, fornecendo recomendações para produtos complementares e incentivando o cliente a comprar novamente.

Definindo os modelos de receita para a solução

Existem diferentes modelos de receita que podem ser utilizados para a solução proposta, dependendo da estratégia de negócio da marca. Abaixo, estão alguns modelos que podem ser considerados:

- Venda de software: A marca pode vender a solução como um software para outras empresas, permitindo que elas usem as funcionalidades de inteligência artificial em suas próprias plataformas.
- Assinatura: A marca pode oferecer a solução como um serviço de assinatura, cobrando dos clientes um valor mensal ou anual para ter acesso às funcionalidades de recomendação personalizada.
- Comissão sobre vendas: A marca pode cobrar uma comissão sobre as vendas realizadas a partir das recomendações geradas pela solução.
- Publicidade: A marca pode utilizar a solução para exibir anúncios relevantes aos clientes, cobrando dos anunciantes uma taxa de publicidade.
- Licenciamento de tecnologia: A marca pode licenciar a tecnologia de inteligência artificial desenvolvida para outras empresas, permitindo que elas desenvolvam suas próprias soluções de recomendação personalizada.

Regras de Negócio

RN01: nossos clientes serão chamados de parceiros de negócios;

RN02: os clientes dos nossos clientes (ou seja, os compradores) serão chamados de usuários;

RN03: o parceiro será identificado por um código numérico;

RN04: o parceiro deve informar um nome fantasia;

RN05: deverá existir uma coluna de data para informar a entrada deste parceiro em nosso sistema, bem como uma coluna informando a data de encerramento de contrato com este parceiro;

RN06: a data de encerramento deverá ser obrigatoriamente preenchida somente quando se encerrar o contrato com o parceiro de negócios;

RN07: o parceiro deve informar um CNPJ;

RN08: se o parceiro for um ecommerce, ele pode informar o link do produto comprado

RN09: o usuário será identificado por um código numérico;

RN10: o parceiro deve informar um nome para o usuário;

RN11: o parceiro deve informar o CPF do usuário;

RN12: o parceiro pode informar o CEP da residência do usuário;

RN13: a data de nascimento do usuário pode ser informada;

RN14: o gênero do usuário pode ser informado;

RN15: o item de compra será chamado produto;

RN16: o produto será identificado por um código numérico;

RN17: o produto deve ter uma categoria;

RN18: o produto deverá ter um nome;

RN19: o produto deverá ter uma categoria;

RN20: um parceiro pode ter vários produtos;

RN21: a transação será identificada por um código numérico;

RN22: cada transação deve conter o código do usuário e o código do parceiro de negócios;

RN23: cada transação tem obrigatoriamente um usuário e um parceiro;

RN24: uma transação pode ter mais de um produto;

RN25: a data da transação deve ser mantida;

RN26: um usuário pode ter várias transações;

RN27: um parceiro pode ter várias transações;

RN28: o valor de cada produto deve ser apresentado individualmente;

RN29: o valor total da compra deve ser apresentado;

RN30: a transação pode informar o CEP do estabelecimento da compra;

RN31: o status da transação deve ser apresentado em valor booleano (sim ou não);

RN32: cada recomendação é identificada por um código;

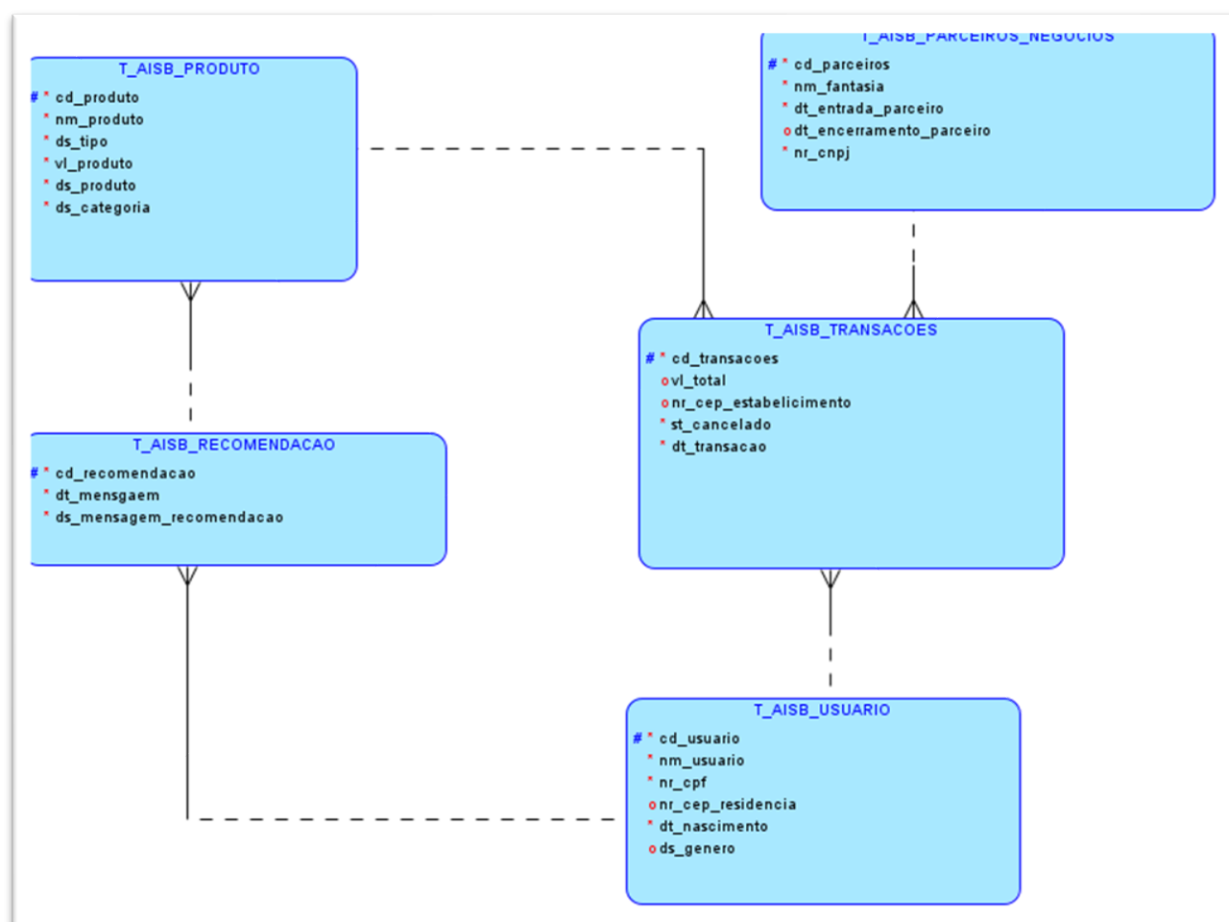
RN33: cada recomendação possui um usuário, mas um usuário pode ter várias recomendações;

RN34: a recomendação tem obrigatoriamente uma data de quando foi feita;

RN35: a mensagem de recomendação feita pela API do ChatGPT deve ser salva em uma coluna;

RN36: uma recomendação pode ter vários produtos;

Projeto Lógico do Banco de Dados



Projeto Relacional do Banco de Dados

