



SHOPPING BUDDY

**we make
better
shop carts**

FIAP + PLUSOFT

SÃO PAULO, 2023

DATABASE APPLICATION & DATA SCIENCE



CHALLENGE

SOBRE O PROJETO

Neste projeto, será desenvolvido um sistema de recomendação personalizado para fornecer sugestões precisas aos clientes com base em seus históricos de compras e interações anteriores com a marca. O sistema será baseado em técnicas de Machine Learning, permitindo que o ChatGPT aprenda com as interações anteriores e melhore continuamente suas sugestões. O objetivo do projeto é aumentar a satisfação do cliente, melhorar a fidelidade do cliente e aumentar as vendas da marca.

INTEGRANTES

Enzo Perazolo	RM95657
Giovanna Sousa	RM94767
Henry Kinoshita	RM93443
Luiz Felipe	RM94538
Matheus Felipe	RM93772
Victor Mendes	RM92843

Descrição do Projeto e Regras de Negócios Declaração de Visão e Escopo do Projeto
Descrição do problema a resolver:

A jornada do cliente (CX) é uma parte crucial do sucesso de qualquer negócio. No entanto, muitas empresas lutam para fornecer uma experiência personalizada e satisfatória para seus clientes. O problema é a falta de uma solução eficiente para fornecer recomendações personalizadas e prever as necessidades dos clientes com base em seu histórico de compras e interações anteriores com a marca.

Descrição dos objetivos da solução idealizada:

O objetivo desta solução é utilizar a tecnologia de Machine Learning para criar um sistema que possa aprender com as interações anteriores dos clientes e fornecer recomendações personalizadas cada vez mais precisas. A solução deve ser capaz de prever as necessidades dos clientes, fornecendo-lhes ofertas personalizadas e melhorando sua experiência de compra.

O sistema é composto por dois componentes principais: um modelo de recomendação e um modelo de previsão:

O modelo de recomendação é treinado com dados históricos de interações do cliente

- com a marca, como compras anteriores, navegação em sites, pesquisas e outros dados relevantes. O modelo usa esses dados para gerar recomendações personalizadas para cada cliente, levando em consideração suas preferências, histórico de compras e outros fatores.

O modelo de previsão utiliza técnicas de Machine Learning para prever as necessidades

- futuras dos clientes com base em seus dados históricos. Ele considera fatores como sazonalidade, tendências de mercado e mudanças nos comportamentos dos clientes. Com base nessas previsões, o modelo é capaz de fornecer recomendações mais precisas e relevantes para os clientes, aumentando a probabilidade de que eles realizem uma compra.

Além disso, a solução também inclui um sistema de feedback que permite aos clientes

- avaliar as recomendações recebidas. Esses feedbacks são usados para ajustar e melhorar continuamente o modelo de recomendação e o modelo de previsão.

Definição do público-alvo que comprará (cliente/pagante) e/ou usará a solução (consumidor):

O público-alvo desta solução são empresas que buscam melhorar a experiência de seus clientes. Os consumidores finais são os clientes das empresas que utilizarão a solução.

As necessidades e desejos do público-alvo em relação ao problema incluem

- Personalização: os clientes desejam uma experiência personalizada e única que atenda às suas necessidades e preferências individuais.

- Facilidade de uso: os clientes querem que a experiência de compra seja fácil e intuitiva, sem barreiras ou obstáculos desnecessários.

- Agilidade: os clientes esperam uma experiência rápida e ágil, sem atrasos ou tempos de espera prolongados.

- Confiança: os clientes desejam confiar na marca e em seus produtos, ter certeza de que estão fazendo uma compra com boa relação custo-benefício.

- Comunicação clara: os clientes querem que as informações fornecidas pela marca sejam claras, precisas e relevantes para suas necessidades.

- Relevância: os clientes esperam que as recomendações e sugestões fornecidas pela marca sejam relevantes e apropriadas para seus interesses e necessidades individuais.

Personalização contínua: os clientes querem que a marca continue a aprender e ajustar

- as recomendações e sugestões ao longo do tempo, para que a experiência continue a ser personalizada e relevante.

Descrição das possíveis bibliotecas e frameworks Python que poderão ser utilizados:

TensorFlow: é uma biblioteca de código aberto para aprendizado de máquina e inteligência

- artificial desenvolvida pela Google. É amplamente utilizada para criação de modelos de redes neurais profundas e pode ser utilizado para a criação de chatbots avançados.

Keras: é uma biblioteca de alto nível para aprendizado de máquina e redes neurais

- escrita em Python, que roda em cima do TensorFlow. É uma das bibliotecas mais utilizadas para criação de modelos de redes neurais e possui uma sintaxe simples e intuitiva.

Scikit-learn: é uma biblioteca de aprendizado de máquina em Python que oferece uma

- ampla variedade de algoritmos para tarefas de classificação, regressão, clusterização, entre outras. É uma das bibliotecas mais populares para análise de dados e criação de modelos de aprendizado de máquina.

- NLTK (Natural Language Toolkit): é uma biblioteca em Python para processamento de linguagem natural. Pode ser utilizado para lidar com tarefas como tokenização, lematização, análise de sentimentos, entre outras.

- Pandas: é uma biblioteca em Python para manipulação e análise de dados. É frequentemente utilizada para limpeza, transformação e análise de dados em projetos de aprendizado de máquina e inteligência artificial.

No projeto proposto, a IA (Inteligência Artificial) será utilizada para desenvolver um sistema de recomendação personalizada para os clientes, a fim de prever suas necessidades com base em seu histórico de compras e interações anteriores com a marca. Para isso, serão utilizados algoritmos de aprendizado de máquina e redes neurais, que serão treinados com os dados históricos dos clientes, a fim de prever suas necessidades e fornecer recomendações precisas e personalizadas.

O conceito de LOT (Language of Thought) também será utilizado na solução proposta. Isso porque, a partir das interações com os clientes, será possível aprender a linguagem específica utilizada pelos clientes e criar um modelo cognitivo da linguagem desses clientes. Com essa informação, a IA poderá ser treinada para compreender melhor as necessidades e desejos dos clientes e fornecer recomendações mais precisas e personalizadas.

Além disso, a utilização da linguagem natural na interação com os clientes também será fundamental para a solução proposta. Com o uso de bibliotecas como NLTK (Natural Language Toolkit) e TensorFlow, será possível treinar modelos de processamento de linguagem natural para compreender melhor as necessidades e desejos dos clientes e fornecer recomendações mais precisas e personalizadas.

Em resumo, a IA e o conceito de LOT serão utilizados de forma integrada na solução proposta, a fim de criar um sistema de recomendação personalizada e inteligente, capaz de compreender a linguagem dos clientes e prever suas necessidades com base em seu histórico de compras e interações anteriores com a marca.

Estudo de produtos semelhantes já existentes no mercado (que solucionam o mesmo problema, mesmo que de forma diferente, parcial ou totalmente):

Há muitas soluções de recomendação personalizadas no mercado, desde sistemas de recomendação de filmes até recomendações de produtos em lojas online. No entanto, a maioria dessas soluções não utiliza Machine Learning para melhorar a precisão das recomendações e não levam em conta o histórico completo de interações com a marca. A solução proposta irá superar essas limitações.

- Amazon Personalize: a Amazon oferece um serviço de personalização de recomendação que permite que as empresas personalizem suas recomendações de produtos com base no histórico de compras e no comportamento do usuário.

- Salesforce Einstein: o Salesforce Einstein é uma plataforma de inteligência artificial que ajuda as empresas a oferecer recomendações personalizadas para seus clientes.

- Adobe Target: a Adobe Target é uma plataforma de personalização que usa dados do cliente e inteligência artificial para fornecer recomendações personalizadas.

- Google Analytics 360: o Google Analytics 360 é uma plataforma de análise de dados que ajuda as empresas a entender o comportamento do cliente e fornecer recomendações personalizadas.

- Dynamic Yield: a Dynamic Yield é uma plataforma de personalização omnichannel que usa aprendizado de máquina para fornecer recomendações personalizadas e experiências personalizadas para os clientes.

Para se destacar em relação aos produtos concorrentes, a solução proposta pode explorar as seguintes oportunidades de diferenciação:

- Integração com outras ferramentas de CX: a solução pode se integrar com outras ferramentas de CX (Customer Experience), como plataformas de e-commerce e ferramentas de análise de dados, para fornecer uma experiência de compra mais integrada e completa.

- Foco em segmentos específicos de mercado: a solução pode se concentrar em atender a segmentos específicos de mercado, como nichos de mercado ou setores da indústria, com recursos personalizados e adaptados às suas necessidades.

- Monitoramento contínuo do feedback do cliente: a solução pode incorporar recursos de monitoramento e análise contínua do feedback do cliente para garantir que as recomendações e sugestões permaneçam relevantes e atualizadas ao longo do tempo.

Avaliação do potencial de mercado (fatia de mercado a conquistar):

O mercado para soluções de recomendação personalizadas está em crescimento, com muitas empresas buscando maneiras de melhorar a experiência do cliente. A solução proposta tem potencial para conquistar uma fatia significativa do mercado, uma vez que será capaz de fornecer recomendações cada vez mais precisas e personalizadas, melhorando a satisfação do cliente e aumentando a fidelidade do cliente para com a marca.

1. Aumento da demanda por experiências de compra personalizadas: os consumidores estão cada vez mais em busca de experiências de compra personalizadas, o que cria uma oportunidade para soluções que utilizam aprendizado de máquina e análise de dados para fornecer recomendações e sugestões personalizadas.

2. Crescimento do mercado de CX: o mercado de CX está em constante crescimento e deve continuar crescendo nos próximos anos, criando uma oportunidade para soluções que oferecem uma experiência de compra mais personalizada e integrada.

3. Ampliação da adoção de tecnologias de IA: a adoção de tecnologias de inteligência artificial, como aprendizado de máquina, está em constante crescimento, o que cria uma oportunidade para soluções que utilizam essas tecnologias para fornecer uma experiência de compra mais personalizada e adaptada às necessidades do cliente.

4. Diferenciação em relação aos concorrentes: oferecer recursos e funcionalidades exclusivas e diferentes dos concorrentes pode ajudar a solução proposta a se destacar no mercado e conquistar uma fatia maior de clientes em busca de uma experiência de compra personalizada.

5. Expansão para novos mercados: a solução proposta pode ser expandida para novos mercados e setores da indústria, adaptando-se às necessidades e demandas específicas de cada segmento e aumentando seu potencial de crescimento no mercado.

A solução proposta cria valor para o público-alvo de diversas formas:

- Melhora a experiência do cliente: Ao fornecer recomendações mais precisas e personalizadas, a solução melhora a experiência do cliente, aumentando a satisfação e a fidelidade à marca.

- Economiza tempo: Ao antecipar as necessidades do cliente, a solução economiza tempo do cliente ao tornar mais rápida e fácil a busca por produtos que atendam suas necessidades.
- Aumenta a relevância: Ao fornecer recomendações personalizadas, a solução aumenta a relevância das ofertas, aumentando a probabilidade de o cliente comprar e, consequentemente, aumentando as vendas da marca.
- Melhora a eficiência: Ao utilizar técnicas de inteligência artificial, a solução pode processar grandes quantidades de dados de forma eficiente e automatizada, permitindo que a marca ofereça recomendações personalizadas para um grande número de clientes simultaneamente.
- Estimula a compra recorrente: A solução pode ser utilizada para incentivar a compra recorrente, fornecendo recomendações para produtos complementares e incentivando o cliente a comprar novamente.

Definindo os modelos de receita para a solução

Existem diferentes modelos de receita que podem ser utilizados para a solução proposta, dependendo da estratégia de negócio da marca. Abaixo, estão alguns modelos que podem ser considerados:

- Venda de software: A marca pode vender a solução como um software para outras empresas, permitindo que elas usem as funcionalidades de inteligência artificial em suas próprias plataformas.
- Assinatura: A marca pode oferecer a solução como um serviço de assinatura, cobrando dos clientes um valor mensal ou anual para ter acesso às funcionalidades de recomendação personalizada.
- Comissão sobre vendas: A marca pode cobrar uma comissão sobre as vendas realizadas a partir das recomendações geradas pela solução.
- Publicidade: A marca pode utilizar a solução para exibir anúncios relevantes aos clientes, cobrando dos anunciantes uma taxa de publicidade.
- Licenciamento de tecnologia: A marca pode licenciar a tecnologia de inteligência artificial desenvolvida para outras empresas, permitindo que elas desenvolvam suas próprias soluções de recomendação personalizada.

Regras de Negócio

RN01: nossos clientes serão chamados de parceiros de negócios;

- RN02: os clientes dos nossos clientes (ou seja, os compradores) serão chamados de usuários;

RN03: o parceiro será identificado por um código numérico;

RN04: o parceiro deve informar um nome fantasia;

- RN05: deverá existir uma coluna de data para informar a entrada deste parceiro em nosso sistema, bem como uma coluna informando a data de encerramento de contrato com este parceiro;

- RN06: a data de encerramento deverá ser obrigatoriamente preenchida somente quando se encerrar o contrato com o parceiro de negócios;

RN07: o parceiro deve informar um CNPJ;

- RN08: se o parceiro for um ecommerce, ele pode informar o link do produto comprado

RN09: o usuário será identificado por um código numérico;

RN10: o parceiro deve informar um nome para o usuário;

RN11: o parceiro deve informar o CPF do usuário;

RN12: o parceiro pode informar o CEP da residência do usuário;

RN13: a data de nascimento do usuário pode ser informada;

RN14: o gênero do usuário pode ser informado;

RN15: o item de compra será chamado produto;

RN16: o produto será identificado por um código numérico;

RN17: o produto deve ter uma categoria;

RN18: o produto deverá ter um nome;

RN19: o produto deverá ter uma categoria;

RN20: um parceiro pode ter vários produtos;

RN21: a transação será identificada por um código numérico;

- RN22: cada transação deve conter o código do usuário e o código do parceiro de negócios;

RN23: cada transação tem obrigatoriamente um usuário e um parceiro; RN24: uma transação pode ter mais de um produto;

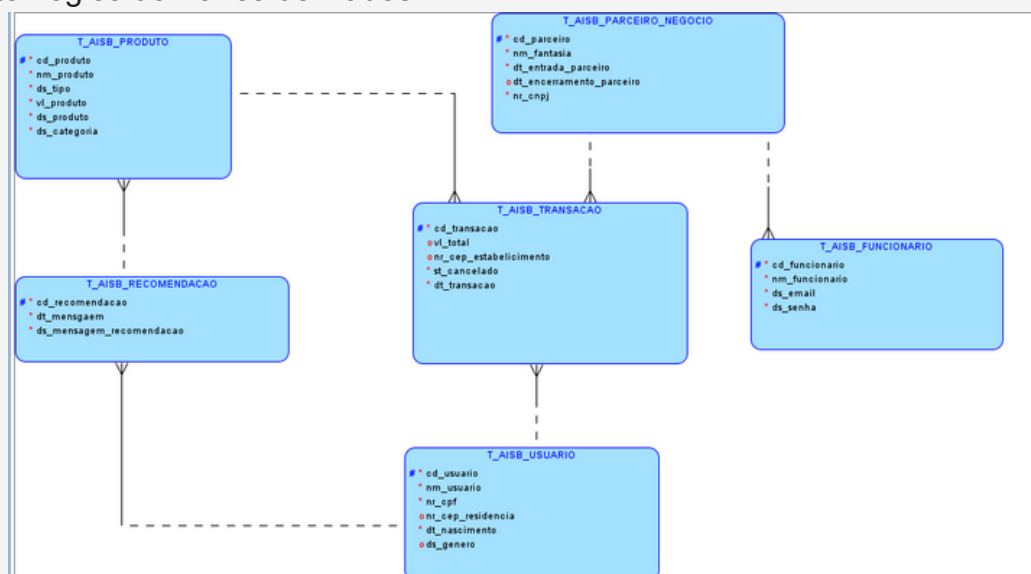
RN25: a data da transação deve ser mantida;

RN26: um usuário pode ter várias transações;

-

- RN27: um parceiro pode ter várias transações;
- RN28: o valor de cada produto deve ser apresentado individualmente;
- RN29: o valor total da compra deve ser apresentado;
- RN30: a transação pode informar o CEP do estabelecimento da compra;
- RN31: o status da transação deve ser apresentado em valor booleano (sim ou não);
- RN32: cada recomendação é identificada por um código;
- RN33: cada recomendação possui um usuário, mas um usuário pode ter várias recomendações;
- RN34: a recomendação tem obrigatoriamente uma data de quando foi feita;
- RN35: a mensagem de recomendação feita pela API do ChatGPT deve ser salva em uma coluna;
- RN36: uma recomendação pode ter vários produtos;
- RN37: o funcionário deve ser identificado por um código numérico;
- RN38: o parceiro deve informar o nome do funcionário e seu email;
- RN39: um parceiro pode ter um ou mais funcionários cadastrados;
- RN40: um parceiro pode ter várias recomendações de um mesmo usuário;
-

Projeto Lógico do Banco de Dados



Projeto Relacional do Banco de Dados

